实验 3_文本情感分析

提交人：GaoT

日期：2026 年 3 月

一、 基础模型

1. 文本特征提取

   分别采用 3 种统计模型进行特征提取：词袋模型 BOW、N-gram 模型(N=2)、TF-IDF 模型

2. 分类器

   采用简单线性分类器，最小化 Hinge Loss。

   反向传播公式的推导如下：

   把每条影评文本x映射为对应的特征向量$\boldsymbol{\phi}(x)$，简单线性模型的预测得分为：

   $$f(x) = \mathbf{w} \cdot \boldsymbol{\phi}(x)$$

   Hinge Loss为：

   $$L(y, f(x)) = \max(0, 1 - y * f(x))$$

   其中y是真实标签（$+1$或-1）。带入$f(x)$的公式得到：

   $$\begin{aligned} L(x, y; \mathbf{w}) &= \max(0, 1 - \mathbf{w} \cdot \boldsymbol{\phi}(x) y) \\ &= \begin{cases} 1 - \mathbf{w} \cdot \boldsymbol{\phi}(x) y, & \text{if } \mathbf{w} \cdot \boldsymbol{\phi}(x) y < 1 \\ 0, & \text{if } \mathbf{w} \cdot \boldsymbol{\phi}(x) y \geq 1 \end{cases} \end{aligned}$$

   反向传播需要计算损失函数对权重$\mathbf{w}$的偏导数：$\frac{\partial L}{\partial \mathbf{w}}$， 当$\mathbf{w} \cdot \boldsymbol{\phi}(x) y < 1$时：

   $$L(x, y; \mathbf{w}) = 1 - \mathbf{w} \cdot \boldsymbol{\phi}(x) y = 1 - y \cdot \sum_i \mathbf{w}_i \cdot \boldsymbol{\phi}_i(x)$$

   对第j个权重$\mathbf{w}_j$求偏导：

   $$\frac{\partial L}{\partial \mathbf{w}_j} = \frac{\partial}{\partial \mathbf{w}_j}(1 - y \cdot \sum_i \mathbf{w}_i \cdot \boldsymbol{\phi}_i(x)) = -y \cdot \boldsymbol{\phi}_j(x)$$

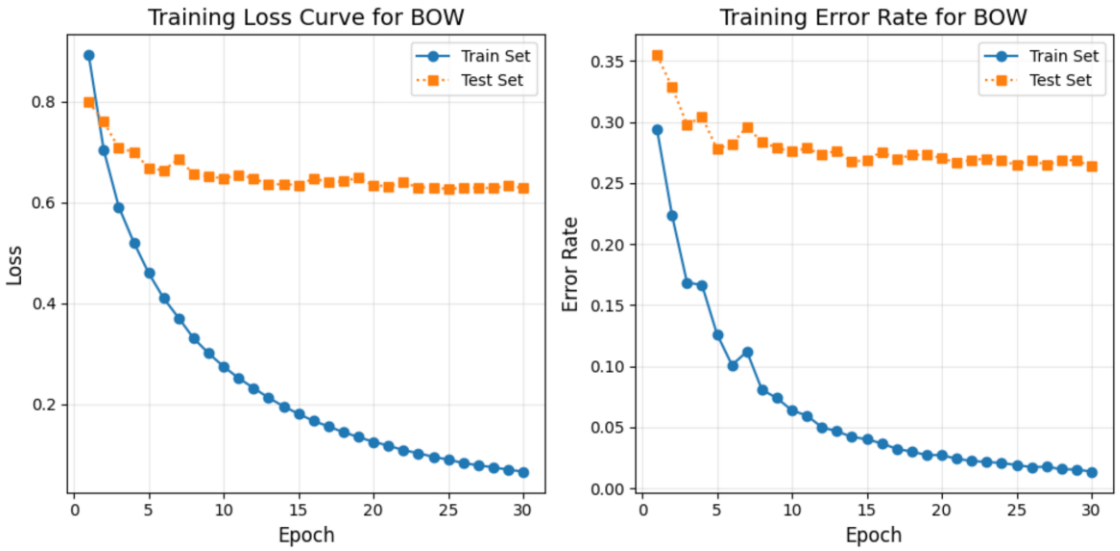
   当$\mathbf{w} \cdot \boldsymbol{\phi}(x) y \geq 1$时：$\frac{\partial L}{\partial \mathbf{w}_j} = 0$。

   完整的向量形式反向传播公式为：

   $$\frac{\partial L}{\partial \mathbf{w}} = \begin{cases} -y \cdot \boldsymbol{\phi}(x), & \text{if } \mathbf{w} \cdot \boldsymbol{\phi}(x) y < 1 \\ 0, & \text{if } \mathbf{w} \cdot \boldsymbol{\phi}(x) y \geq 1 \end{cases}$$

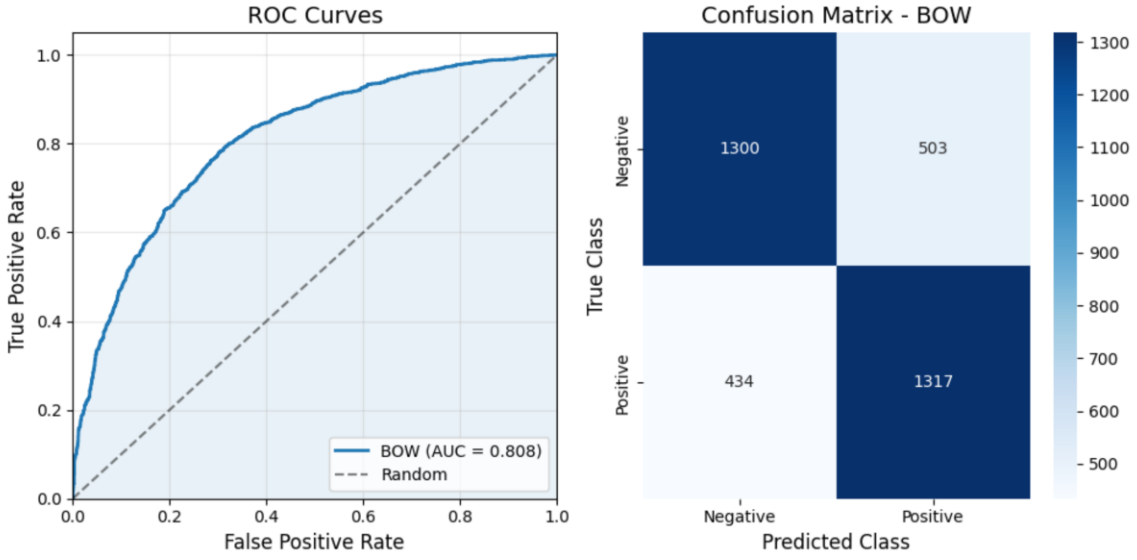
3. 模型训练和测试

（1） BOW： epoch = 30, learning_rate = 0.01

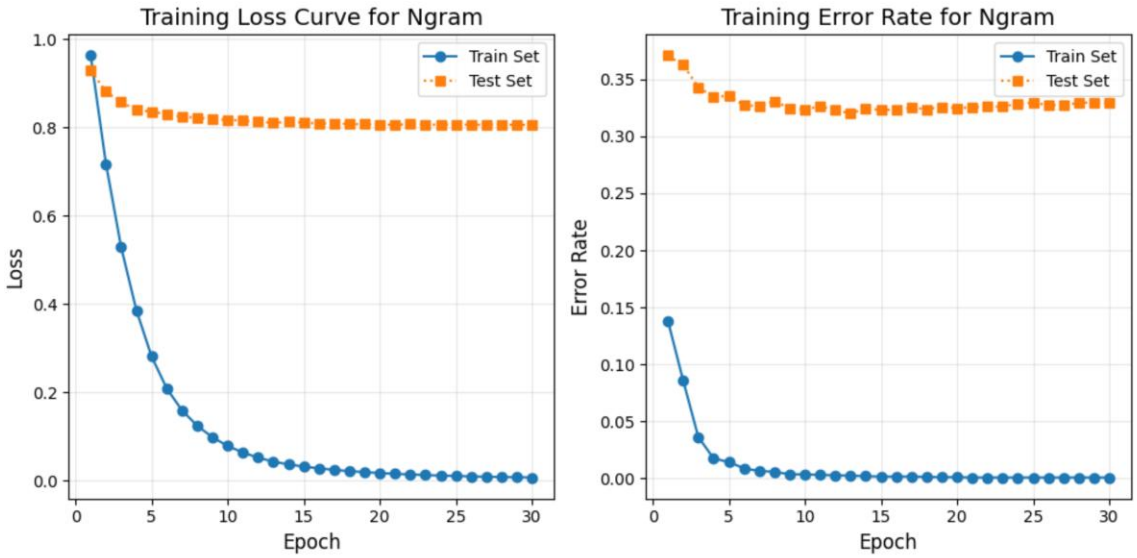


损失函数在 Epoch30 附近仍然在缓慢下降，但测试集在 Epoch10 附近已经收敛。虽然通过增加训练轮数可以继续提高训练集的表现，但很明显这个提升并不能泛化，可能导致过拟合。该模型在训练集上的错误率在 25%以上，最终模型在测试集上的表现如下：

```
==================================================
Evaluation Results on Test Set for BOW
==================================================
Accuracy:  0.7364 (73.64%)
F1 Score:  0.7376
AUC:       0.8080
```

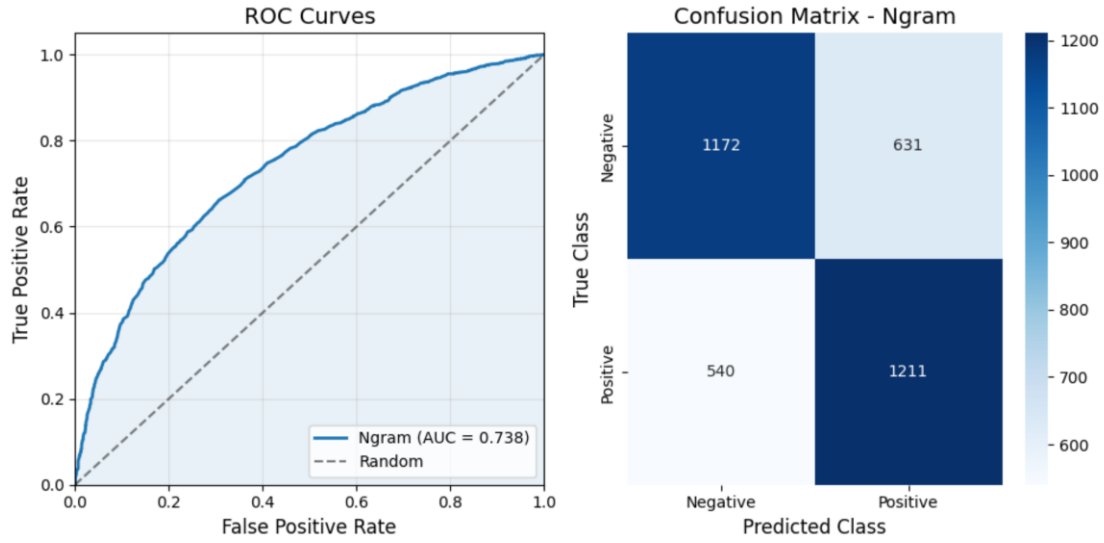


（2） N-gram： N = 2, epoch = 30, learning_rate = 0.01

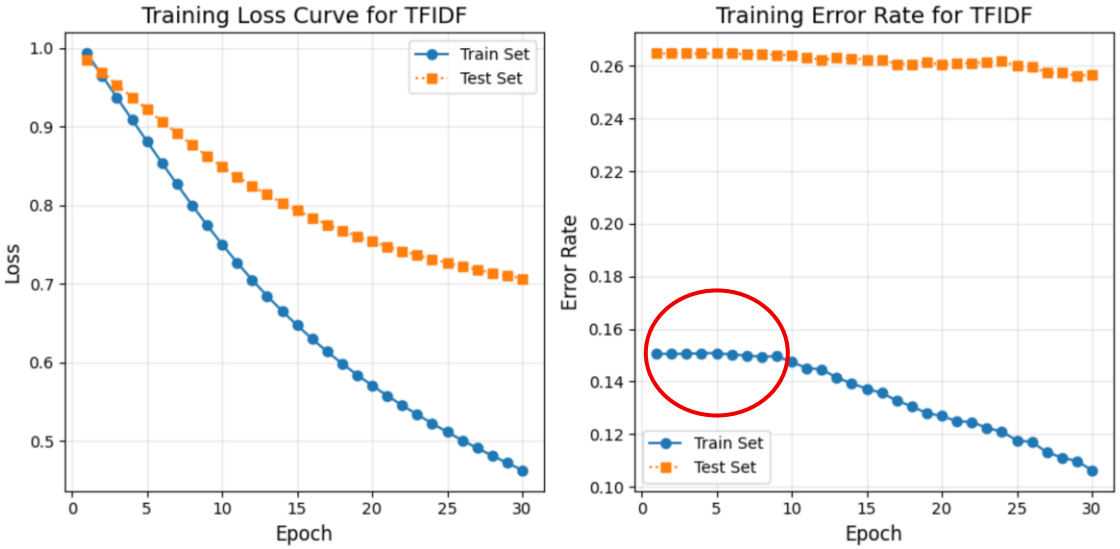


损失函数与错误率的收敛速度明显快于 BOW（本实验 BOW 等价于 1-gram），模型呈现过拟合状态，且模型泛化性较差，在测试集上的表现较差。N-gram 在情感分类上并没有明显优势。情感表达往往单个词就能表达，2-gram 可能能捕捉到更多的否定表达（两个单词），本实验数据中如果否定表达不多的话实际上并不能很好地进行泛化训练。另外本实验数据集较小（训练集和测试集分别有 3554 条），每种否定 2-gram 出现的频率较低，模型很难学到 2-gram 的规律。

```
==================================================
Evaluation Results on Test Set for Ngram
==================================================
Accuracy:  0.6705 (67.05%)
F1 Score:  0.6741
AUC:       0.7378
```

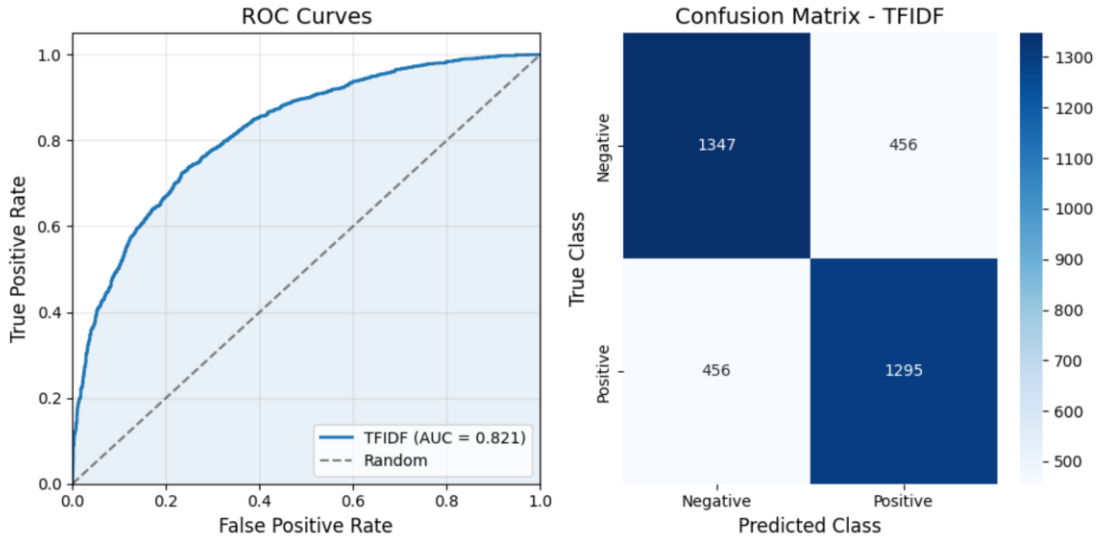


（3） TF-IDF： epoch = 30, learning_rate = 0.01



不同于一般的情况，训练集在前 10 个 epoch 基本不变，之后的 epoch 又线性减小，这个现象很有趣。训练集的错误率在第 1 个 epoch 就接近收敛，可见模型很稳健，TF-IDF 确实能更有效地提炼重要的词。最终在训练集上表现比 BOW 略好：

```
==================================================
Evaluation Results on Test Set for TFIDF
==================================================
Accuracy:  0.7434 (74.34%)
F1 Score:  0.7396
AUC:       0.8213
```



二、 词向量模型

1. Word2Vec

使用预训练的词向量，考虑到计算机内存限制和本实验数据量，选择 100 维的 GloVe 而不是 Word2vec 作为预训练词向量。句子向量采用词向量地平均。

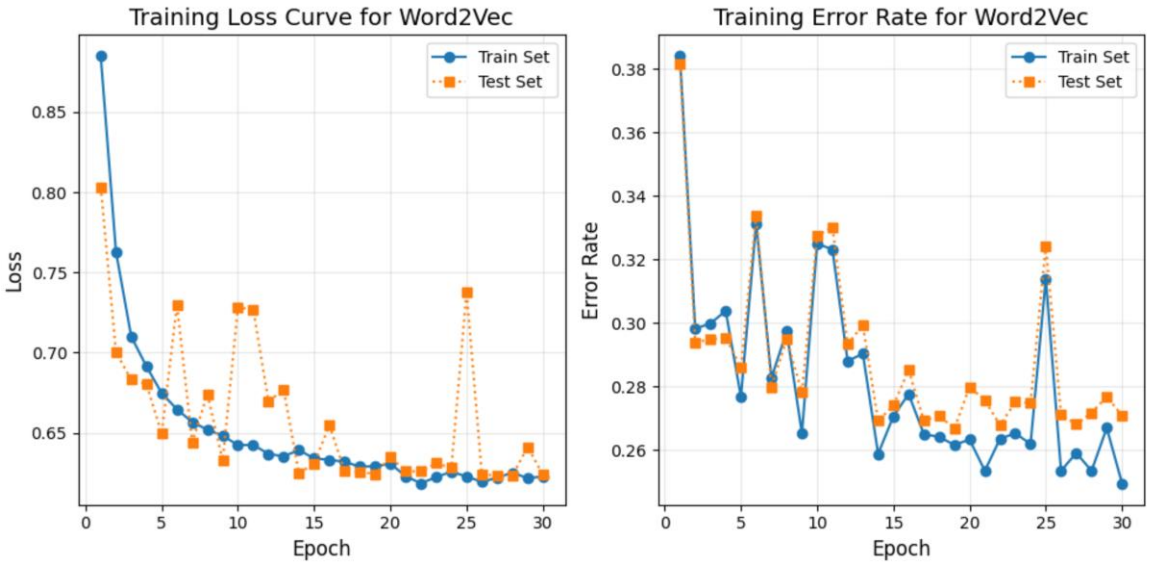
```
from gensim.models import KeyedVectors
import os

# GloVe文件
glove_file = 'glove.6B.100d.txt'

# 使用word2vec加载器
word_vectors = KeyedVectors.load_word2vec_format(
    glove_file,
    binary=False,
    no_header=True,  # 告诉gensim：这个文件没有头部信息
    encoding='utf-8'
)

print(f"加载成功！词汇表大小：{len(word_vectors.key_to_index)}")
print(f"向量维度：{word_vectors.vector_size}")
```

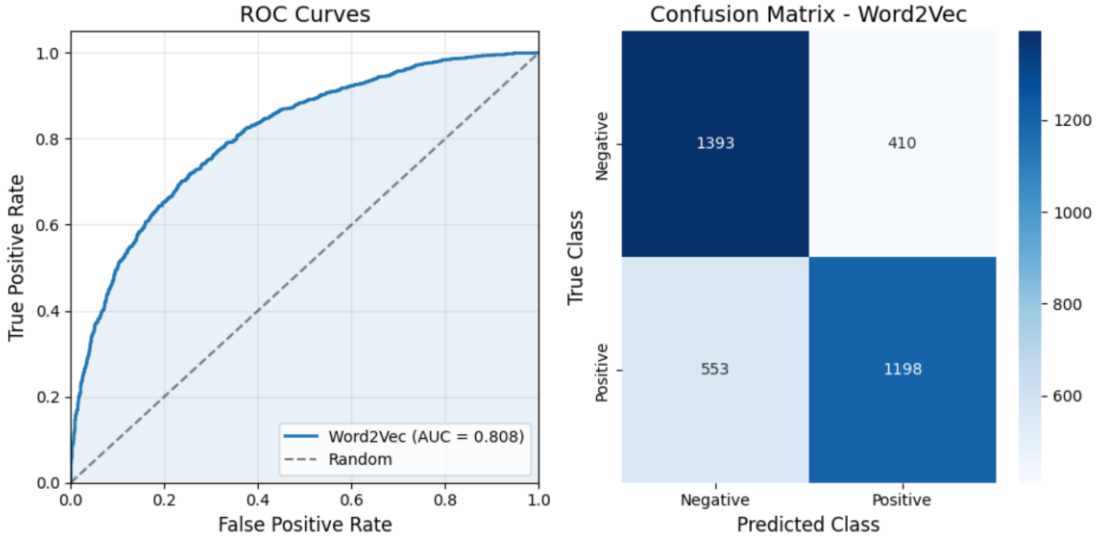
```
加载成功！词汇表大小：400000
向量维度：100
```



与之前的模型很明显的区别是，不论是损失函数还是错误率曲线，测试集都与训练集很接近，可以认为该模型的泛化能力很高。原因是采用了预训练的词向量而不是从训练集中获得的，词向量

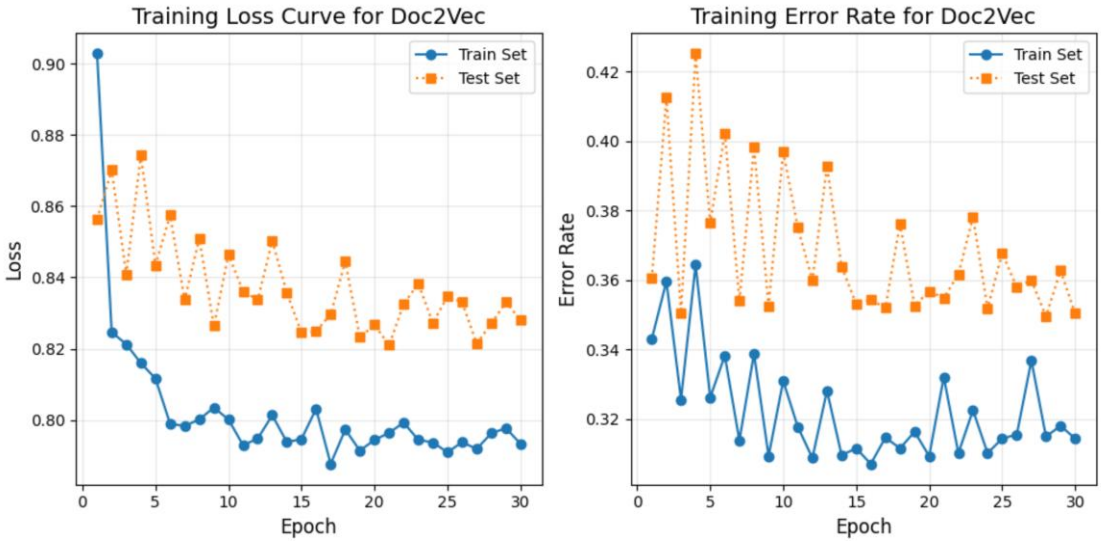
的特征来自于更普遍更大量的文本，能更好地提取词义和词间的关系。不过最终测试集上的评价指标并没有比之前统计模型有明显优势。从混淆矩阵热力图可以看到，该模型召回率偏低。

```
==================================================
Evaluation Results on Test Set for Word2Vec
==================================================
Accuracy:  0.7290 (72.90%)
F1 Score:  0.7133
AUC:       0.8083
```



2. Doc2Vec

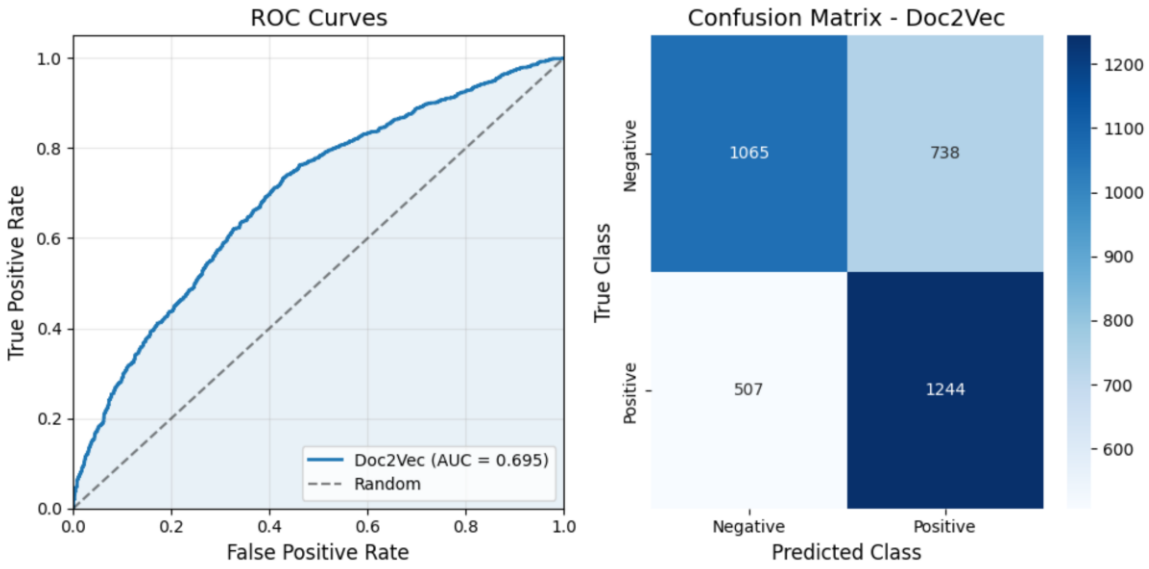
使用 genism 的 Doc2Vec 直接对句子特征提取，转化成向量。与 Word2Vec 类似，验证集的损失函数以及错误率曲线与训练集的差距较统计模型小，特征向量更多地学习到了语义。



但从上图可以看出测试集和训练集地曲线没有 Word2Vec 拟合得好，主要原因：Word2Vec 使用了预训练模型，该模型已经在大量语料库上学习到了大量语义和词间关系，而 Doc2Vec 只是用了训练集，且本实验训练集规模较小（3554 条短文本）。

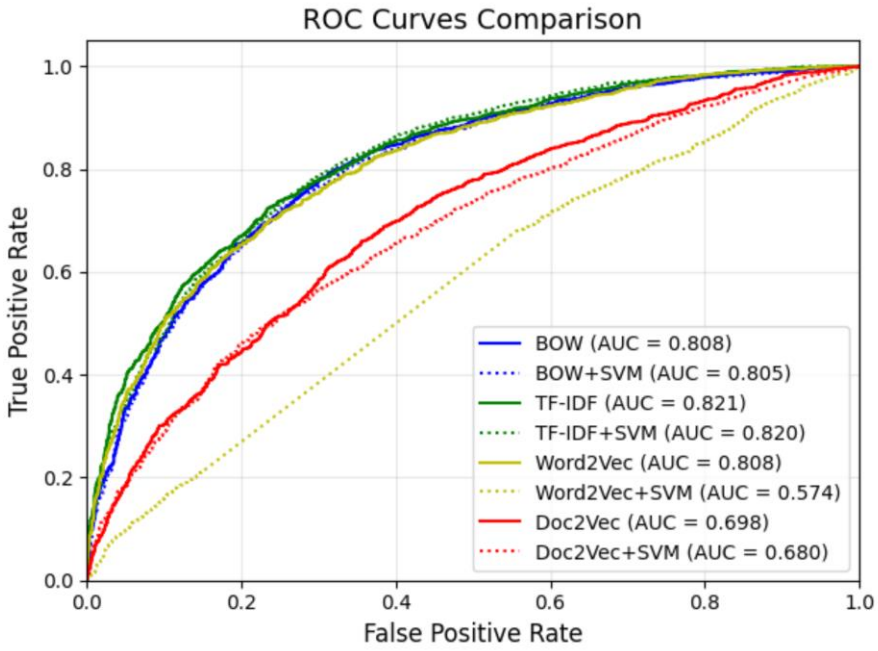
从测试集的评价指标可以看出该模型的分类效果远不如 Word2Vec，甚至比统计特征提取模型还差。首先模型效果取决于 Doc2Vec 的训练效果，Doc2Vec 的超参还有调节优化空间；其次，在情感分类任务中，词表示比句子表示更能提取有用信息，我们关注的是句子中表达情感的词的词义以及否定词，而不关注整个句子的含义。

```
==================================================
Evaluation Results on Test Set for Doc2Vec
==================================================
Accuracy:  0.6497 (64.97%)
F1 Score:  0.6665
AUC:       0.6946
```



三、 SVM 分类器

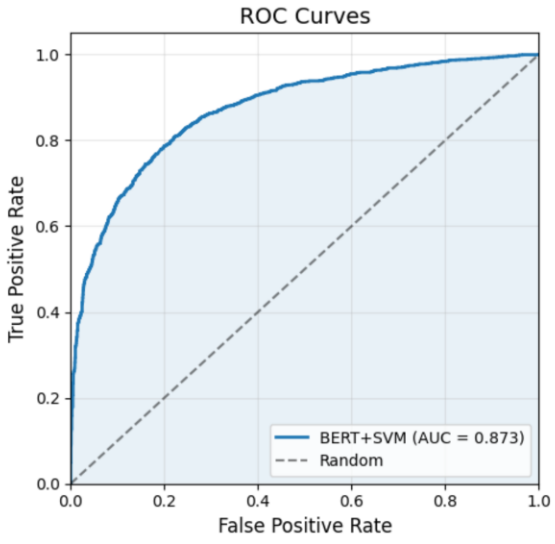
尝试使用 SVM 代替手写的简单线性分类器，并比较不同特征提取方法下的 ROC 曲线。结果显示在本实验中，SVM 并没有比简单线性分类器更好，甚至整体表现还差一些，特别是 Word2Vec 词向量（实际上是 GloVe 词向量）。GloVe 向量的数值分布特点与 SVM 优化器的默认设置不匹配，导致无法很好地收敛，简单的 SGD 分类器可能比追求严格最优解的 SVM 更稳定、效果更好。

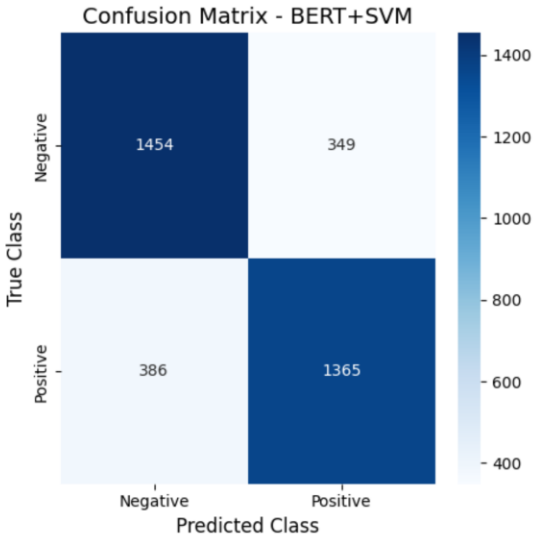


四、 其他尝试

使用 BERT 的[CLS]向量作为句子表示，测试集上的评价指标比之前的词/句子表示明显提高。

```
================================================
Evaluation Results on Test Set for BERT+SVM
================================================
Accuracy:  0.7932 (79.32%)
F1 Score:  0.7879
AUC:       0.8726
```





不同特征提取模型下测试集评价指标对比：

	BOW	N-gram	TF-IDF	Word2Vec	Doc2Vec	BERT+SVM
accuracy	0.7364	0.6705	0.7434	0.7290	0.6483	0.7932
f1	0.7376	0.6741	0.7396	0.7133	0.6514	0.7879
roc_auc	0.8080	0.7378	0.8213	0.8083	0.6979	0.8726

模型特点比较：

模型	预训练任务 / 构造方式	学习目标 / 特征本质	本实验表现
BOW / N-gram / TF-IDF	**无预训练**，基于训练集统计构造	统计词频或词频-逆文档频率，**无语义理解**，只捕捉词的存在与否	较好
Word2Vec / GloVe	基于**词共现**的静态预训练	学习词的静态语义，忽略上下文，**一个词对应一个固定向量**	较好
Doc2Vec	在任务数据上**自训练**，或使用预训练词向量初始化	学习文档主题的向量表示，能捕捉全局主题，但忽略局部词序	较差
BERT	大规模语料上的**掩码语言模型 + 下一句预测**	学习**深层的上下文语义和句间关系**，动态表示，每个词的含义随语境变化	很好