实验 5_司法阅读理解

提交人：GaoT

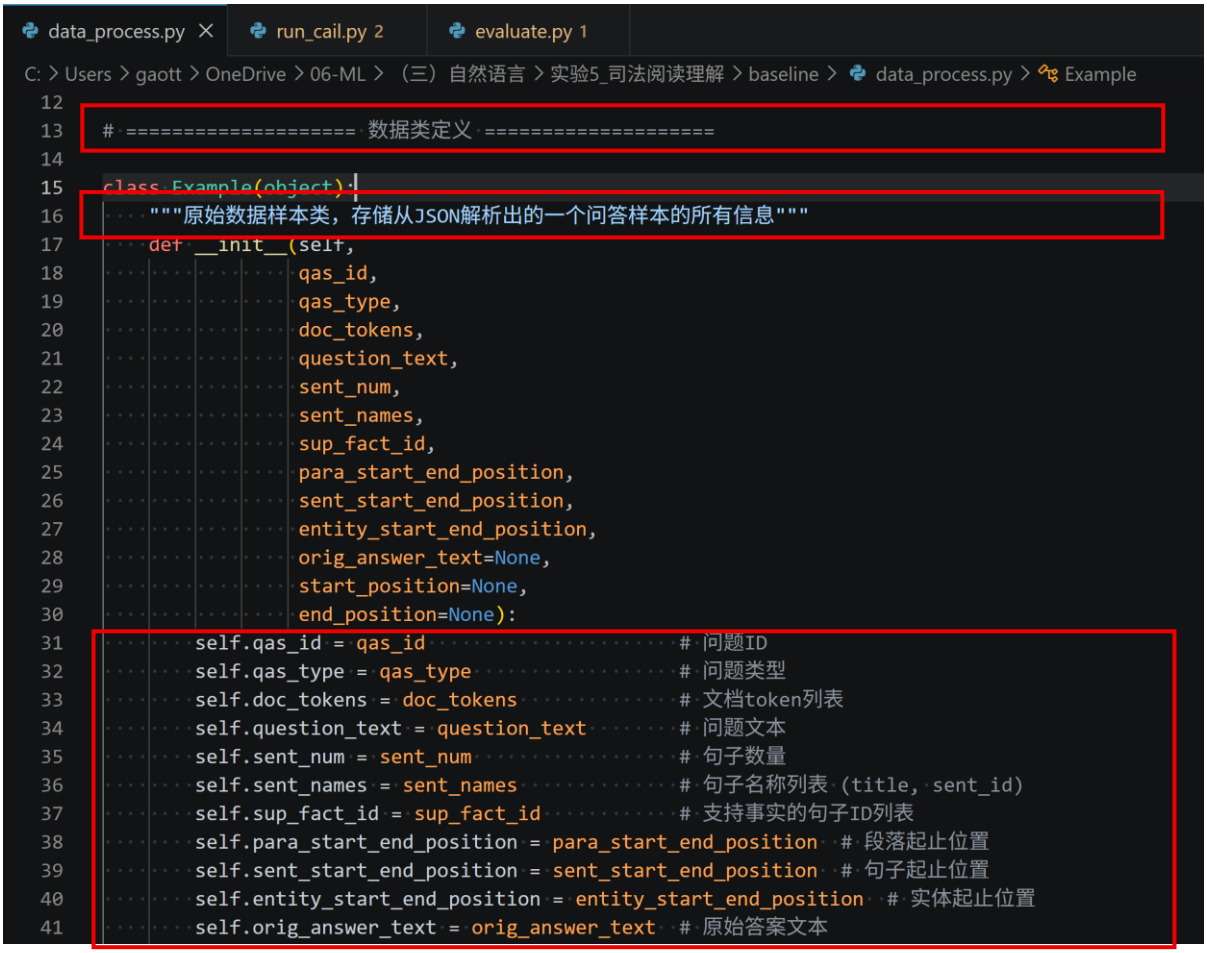
日期：2026 年 4 月

提交文件目录结构：

```
├── hw5_实验报告.pdf                    # 实验报告
├── data_process.py                     # 添加理解注释（原代码实验提供）
├── run_cail.py                         # 添加理解注释（原代码实验提供）
├── modeling.py                         # 添加理解注释（原代码实验提供）
├── evaluate.py                         # 添加理解注释（原代码自行下载）
├── plot_curves.py                      # 获取中间模型的评价指标，作关于 Epoch 的指标曲线
├── pred_seed_52_epoch_10_99999.json    # 基准模型 chinese-bert-wwm 在验证集上推理答案
├── pred_seed_71_epoch_7_99999.json     # 优化模型 chinese-roberta-wwm-ext 的推理答案
```

一、 模型理解和代码解读

该实验实现了一个基于 BERT 的端到端 HotpotQA 问答系统，代码包含三个核心模块：数据预处理、模型训练、模型评估，分别在 ***data_process.py***、***run_cail.py***、***modeling.py***、***evaluate.py*** 中添加了理解注释：



训练代码完成了三个子任务：答案边界预测、问题类型分类（yes / no / unknown / span）、支持事实句子识别。

1. 数据预处理

将原始 JSON 数据转换为 BERT 模型输入格式：

- Example 构建：文档 tokenization、句子/段落边界定位、答案位置标注
- Feature 转换：Subword tokenization、位置映射、构建 input_ids/attention_mask
- 特殊处理：答案边界优化搜索、句子 span 截断、多答案位置支持

2. 模型训练

模型架构：BertSupportNet（BERT 编码器 + 三个任务输出头）

代码定义了三层结构：

BertSupportNet (外层/入口)：负责 BERT 编码，是整个模型的入口

|

| 实例化并调用

▼

SupportNet (中间层/包装器)：简单包装，将 BERT 输出传递给预测层

|

| 实例化并调用

▼

SimplePredictionLayer (内层/核心执行层)：执行实际的多任务预测逻辑

损失函数：$Total\ Loss = Loss_{span} + \lambda_{type} \times Loss_{type} + \lambda_{sp} \times Loss_{sp}$

损失组件	对应任务	损失类型
$Loss_{span}$	答案开始/结束位置	交叉熵
$Loss_{type}$	问题类型分类	交叉熵
$Loss_{sp}$	支持事实预测	BCE

训练策略：梯度累积、混合精度(FP16)、学习率 warmup+线性衰减

3. 模型评估

评估维度：答案质量 + 支持事实质量 + 联合指标

评估指标	计算方式	含义
EM	标准化后字符串完全相等	精确匹配率
F1	字符级别 F1	答案相似度
sp_EM/F1	句子集合级别	支持事实准确度
joint_EM/F1	EM/F1 的乘积	答案和 SP 同时正确

4. 数据流转链路

JSON 原始数据

↓ ***read_examples()***

Example(位置标注)

↓ ***convert_examples_to_features()***

InputFeatures(BERT 输入)

↓ ***DataLoader***

Batch 张量

↓ ***BertSupportNet.forward()***

三个任务输出

↓ ***compute_loss()***

联合损失 → 反向传播

↓ ***predict() / eval()***

评估指标(EM/F1/joint)

二、 模型训练和评价

1. 基准模型

采用 ***chinese-bert-wwm*** 作为基准预训练模型，使用原代码的超参数进行模型训练和评价。

由于原代码只是打印训练 loss，但输出了多组中间预测结果，将对每个 epoch 训练完成时的预测结果进行分析比较，找到 10 个 epoch 中的最佳模型。

执行命令：

```
python plot_curves.py output/submissions/train_base data/dev.json
```

运行时的终端输出结果：

```
预测文件目录: output/submissions/train_base
Gold文件路径: data/dev.json
------------------------------------------------
找到 10 个预测文件

评估: Epoch 1, Step 99999
评估: Epoch 2, Step 99999
评估: Epoch 3, Step 99999
评估: Epoch 4, Step 99999
评估: Epoch 5, Step 99999
评估: Epoch 6, Step 99999
评估: Epoch 7, Step 99999
评估: Epoch 8, Step 99999
评估: Epoch 9, Step 99999
评估: Epoch 10, Step 99999
按Epoch顺序: [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]
------------------------------------------------

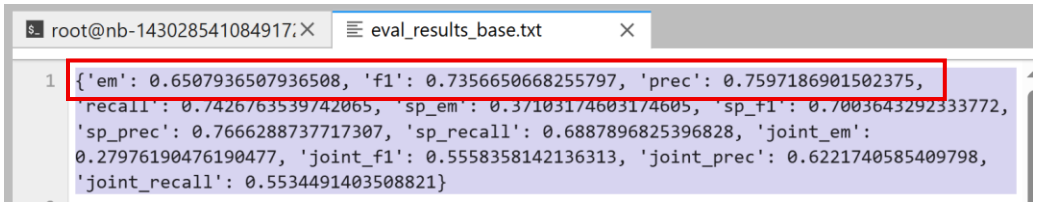
================================================
最佳结果汇总
================================================
最佳 Answer F1:  73.60% (Epoch 7)
最佳 Answer EM:  65.08% (Epoch 10)
最佳 SP F1:      70.04% (Epoch 10)
最佳 Joint F1:   55.58% (Epoch 10)

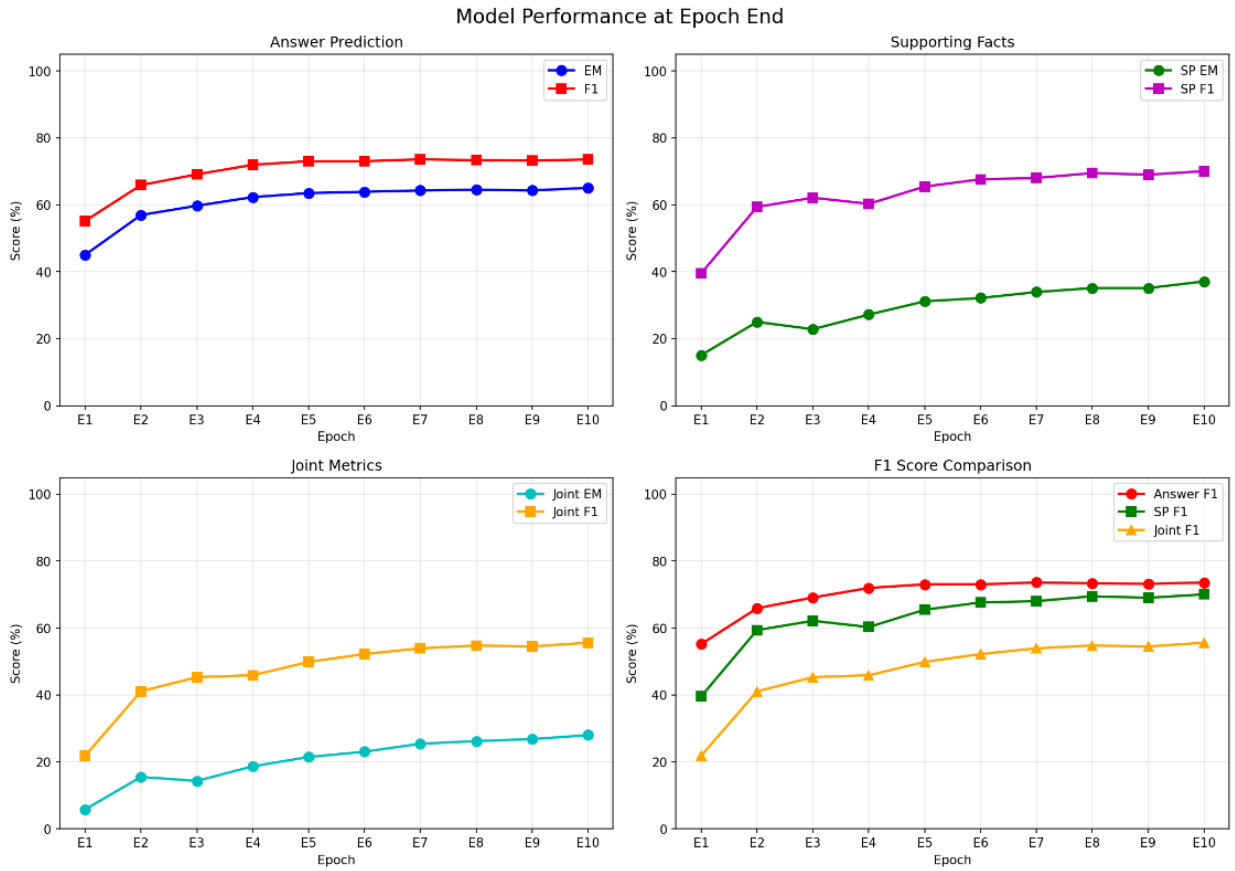
--- 各Epoch详细结果 ---
Epoch 1: Answer F1=55.18%, SP F1=39.52%, Joint F1=21.79%
Epoch 2: Answer F1=65.89%, SP F1=59.37%, Joint F1=41.06%
Epoch 3: Answer F1=69.10%, SP F1=62.12%, Joint F1=45.30%
Epoch 4: Answer F1=71.95%, SP F1=60.27%, Joint F1=45.87%
Epoch 5: Answer F1=73.04%, SP F1=65.46%, Joint F1=49.85%
Epoch 6: Answer F1=73.03%, SP F1=67.61%, Joint F1=52.21%
Epoch 7: Answer F1=73.60%, SP F1=68.02%, Joint F1=53.91%
Epoch 8: Answer F1=73.34%, SP F1=69.49%, Joint F1=54.75%
Epoch 9: Answer F1=73.20%, SP F1=69.01%, Joint F1=54.46%
Epoch 10: Answer F1=73.57%, SP F1=70.04%, Joint F1=55.58%
```

虽然最佳 Answer F1 是 Epoch 7，但实际上 Epoch 7-10 的 Answer F1 都在合理范围内浮动，可以看作基本稳定；而其他几个 F1 值还在缓慢稳定上升。从 F1 值的曲线图也可以看到，模型还在收敛中。

选择 Epoch 10 的推理答案作为验证集结果提交：***pred_seed_52_epoch_10_99999.json***

对应的评价指标为：





2. 优化尝试（使用不同的预训练模型）

采用基准预训练模型 ***chinese-bert-wwm*** 的升级版 ***chinese-roberta-wwm-ext*** 用原代，以及 THUNLP 提供的司法 BERT，将训练结果与基准模型进行比较。其中，司法 BERT 原作者提供了刑事、民事、百度百科三个版本，而实验数据是刑事、民事、行政各约 1700 问答对，预测结果理论上可能并不好。刑事模型无法很好地学习民事、行政样本，民模型无法很好地学习刑事、行政样本，百度百科实际上并没有针对性。

收敛速度比较：

	chinese-bert-wwm	**chinese-roberta-wwm-ext**	**司法刑事(xs)**	**百度百科(bk)**
最佳 Answer F1:	73.60% (Epoch 7)	74.20% (Epoch 7)	67.70% (Epoch 10)	54.44% (Epoch 8)
最佳 Answer EM:	65.08% (Epoch 10)	66.87% (Epoch 7)	59.33% (Epoch 10)	45.63% (Epoch 7)
最佳 SP F1:	70.04% (Epoch 10)	72.80% (Epoch 10)	63.41% (Epoch 10)	57.15% (Epoch 9)
最佳 Joint F1:	55.58% (Epoch 10)	57.36% (Epoch 10)	46.25% (Epoch 10)	36.69% (Epoch 9)

从上面地对比可以看到：

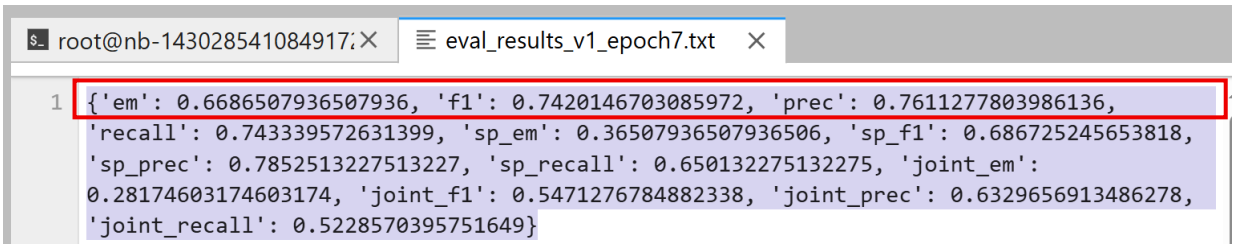
- 基准模型地效果已经很好，最佳答案 F1 达到了 73%以上，EM 也超过了 65%。
- **chinese-roberta-wwm-ext** 比基准模型有所提升，收敛速度加快，F1/EM 值更高，体现了 RoBERTa 模型的架构优势。
- 司法 BERT 的效果并不如基准模型，很明显预训练模型擅长刑事文本理解，而实验数据的 2/3 都是不是刑事文本。我后来考虑到可以挑出刑事数据重新训练模型，比较该预训练模型在纯刑事文本上的表现，但由于时间问题来不及在本报告中体现。
- 百度百科的预训练模型显然学到了更多不专业甚至错误的知识，导致其评价指标数值远低于基础模型。

另外纵向比较各指标，可以发现最佳答案的收敛速度是慢于支持事实的，可以认为准确找到支持事实是比只给出正确答案更加难的。

观察 **chinese-roberta-wwm-ext** 的评价指标变化情况，如果以答案 F1 为标准，可以选择 Epoch 7 的模型为最佳模型：

```
--- 各Epoch详细结果 ---
Epoch 1: Answer F1=54.31%, SP F1=46.21%, Joint F1=27.19%
Epoch 2: Answer F1=62.68%, SP F1=60.85%, Joint F1=40.98%
Epoch 3: Answer F1=66.84%, SP F1=62.58%, Joint F1=45.70%
Epoch 4: Answer F1=69.50%, SP F1=64.38%, Joint F1=48.58%
Epoch 5: Answer F1=72.39%, SP F1=69.69%, Joint F1=54.57%
Epoch 6: Answer F1=73.12%, SP F1=69.47%, Joint F1=54.37%
Epoch 7: Answer F1=74.20%, SP F1=68.67%, Joint F1=54.71%
Epoch 8: Answer F1=72.97%, SP F1=71.59%, Joint F1=55.85%
Epoch 9: Answer F1=72.54%, SP F1=71.61%, Joint F1=56.40%
Epoch 10: Answer F1=73.47%, SP F1=72.80%, Joint F1=57.36%
```

Epoch 7 在验证集上的详细评价指标如下：



在验证集上的推理答案为文件：***pred_seed_71_epoch_7_99999.json***