实验 6_面向肺炎的社会计算应用

提交人：GaoT

日期：2026 年 4 月

一、 课题理解

本实验提供了三种数据，分别是

1、疫情相关谣言 CSDC-Rumor

2、疫情相关中文新闻 CSDC-News

3、疫情相关法律文书 CSDC-Legal

我将**选择第一种数据进行谣言预测**，原因有：

1、谣言数据量虽然最小，但对计算资源要求较低，现有的计算资源能迅速实现；

2、谣言预测是在本课程中没有做过的实验，而新闻数据我能快速想到的分析方法是情感分析，之前已做过类似实验，法律文书之前有过司法阅读实验。

关于谣言检测技术，三种常见的技术类型是：基于特征、基于神经网络、基于传播模型的方法。

方法类别	核心思路	数据需求	可行性
基于特征	人工设计文本特征 → 用统计/机器学习（LR、SVM、随机森林）分类	几百条标签数据	高
神经网络	让模型自动从原始文本中学习特征（CNN、RNN、BERT）	需要大量数据（~万级以上），否则过拟合	中
传播模型	利用转发链、时间序列、用户网络结构来检测	需要完整的转发/评论关系	低

本实验将主要采用特征方法进行谣言预测，也会尝试使用预训练模型 BERT 的神经网络方法，并于特征方法的结果进行比较。

二、 数据概况与数据预处理

实验数据来自清华大学 THUNLP 团队发布的 CSDC-Rumor 数据集，包含两部分：

- 微博谣言数据（rumor_weibo）：2020 年 1 月 22 日至 3 月 3 日期间被认定为不实信息的微博共 **324 条**，每条包含谣言文本（rumorText）、审理结果（result）、发布时间等字段。
- 腾讯/丁香园谣言-事实对（fact.json）：共 **124 条**记录，每条同时包含谣言文本（rumor）和对应的官方/科学事实依据（abstract），并标注了 explain 类型（如“伪科学”、“尚无定论”、“事实”）。

这里的数据统计结果是根据实际结果统计的，与源数据集页面(疫情相关谣言 CSDC-Rumor - COVID-19 社交数据共享平台)的说明略有差异。

微博谣言数据 324 条，但其中一部分谣言文本字段 rumorText 为空，去掉这一部分数据实际使用的谣言数据为 273 条。

```
============================================================
1. 微博谣言数据 (rumor_weibo)
============================================================
文件数量: 324

字段列表:
['rumorCode',
 'title',
 'informerName',
 'informerUrl',
 'rumormongerName',
 'rumormongerUrl',
 'rumorText',
 'visitTimes',
 'result',
 'publishTime',
 'related_url']

示例数据（只显示部分字段）:
  rumorCode: K1CaS7Qth660h
  title: @大不了不练了 投诉@口水垂涎三千尺 不实信息...
  rumorText 长度: 0 字符
  result 长度: 246 字符
  publishTime: 2020-01-22

非空谣言条数: 273

谣言文本长度: 最小=7, 最大=4753, 平均=576
```

腾讯/丁香园谣言数据的每一条记录中除了谣言文本 rumor 外，还提供了事实数据 abstract，可以提取该字段作为正例（事实）。但标签 explain 显示该数据集并不都是谣言，其中一部分是事实。所以需要对所有数据进行整理，构建合理的实验数据集。

```
============================================================
2. 腾讯/丁香园谣言-事实对数据 (fact.json)
============================================================
文件总行数: 124

字段列表:['date', 'explain', 'tag', 'abstract', 'title', 'rumor']

示例数据（第一条）:
  date: 2020-03-18
  explain: 尚无定论
  tag: ['新型冠状病毒', '易感人群']
  abstract: 研究没有正式发表，没有经过同行评议，所以不应被视为结论性的、...
  title: A型血更易感染新冠肺炎，O型血不易感
  rumor: 南方科技大学、上海交大、武汉中南医院、武汉金银潭医院等8家单...

标签 'explain' 分布:
  伪科学: 61
  尚无定论: 43
  确实如此: 19
  伪常识: 1

包含非空 'rumor' 的行数: 124
包含非空 'abstract' 的行数: 124
```

✅ 每条数据同时包含谣言(rumor)和事实(abstract)文本，可构建平衡的谣言-事实对。

数据构建方案

数据来源	说明	用作谣言（负例）	用作事实（正例）
微博谣言（`rumor_weibo`）	全部是谣言	✅ 324条	❌
腾讯/丁香园：伪科学、伪常识	`rumor` 是谣言，`abstract` 是事实	✅ 62条	✅ 62条（abstract）
腾讯/丁香园：确实如此	`rumor` 和 `abstract` 都是事实	❌	✅ 取 `rumor`（或去重后约19条）
腾讯/丁香园：尚无定论	标签不确定	❌ 丢弃	❌ 丢弃

- **平衡数据集**：（62 谣言 + 62 事实，来自伪科学/伪常识）

```
============================================================
平衡数据集实验（谣言62 vs 事实62）
============================================================
谣言样本：62
事实样本：62
去重后总样本：123（谣言:62，事实:61）
```

对原数据详细对比，发现有 1 条事实被用作 2 个谣言的判定依据，需要去重。去重后虽然事实数据少了一条，但仍可看作平衡数据集。

- **完整数据集**：（386 谣言 + 81 事实，来自微博 + 伪科学/伪常识 + 确实如此）

```
============================================================
完整数据集实验（谣言386 vs 事实81）
============================================================
谣言数：335
事实数：80
去重后：总411，谣言331，事实80
```

微博数据的谣言文本也有 51 条重复，最终使用的数据集是去重后的结果。

数据集	谣言（负例）	事实（正例）	总样本
平衡数据集	62	61	123
完整数据集	331	80	411

三、 特征方法

1. 特征词表

参考了前人研究中用于虚假新闻检测的语言特征词表，并结合新冠疫情早期真实数据中的高频词进行了微调。同时，从事实依据文本中统计提取了客观事实标记词，构建了多维度特征集，以全面捕捉谣言与事实文本的差异。

```python
# 特征词表
UNCERTAINTY_WORDS = ['可能', '据说', '大概', '也许', '好像', '网传', '听说', '传闻', '疑似', '据报道', '网曝', '网友称', '约']
EXTREME_WORDS = ['死亡', '爆发', '恐慌', '封城', '感染', '致命', '失控', '紧急', '严重', '蔓延', '扩散', '死人', '灾难', '恐怖', '疯狂', '绝望']
FACT_WORDS = ['根据', '数据显示', '据统计', '官方发布', '卫健委', '专家表示', '研究表明', '证实', '确认', '辟谣']
```

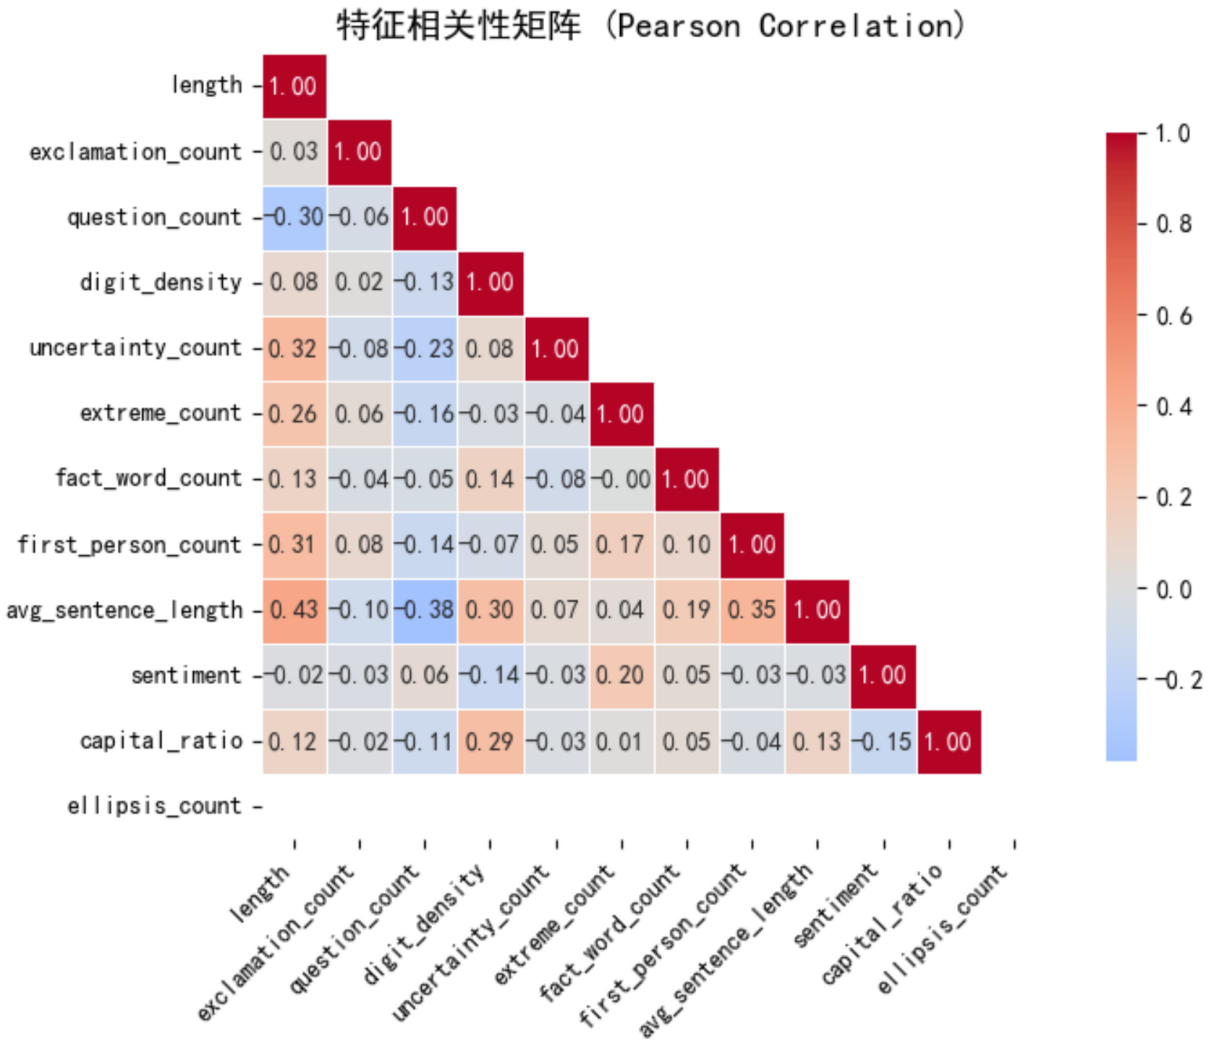
（1）词汇特征：参考已有研究，构建了三类关键特征词表。

- **不确定性词**：这类特征旨在捕捉谣言中常见的模糊和推测性表达。
- **极端情绪词**：基于疫情期间谣言内容的相关分析，选取了高频出现的极负面情感词汇。
- **客观事实词**：通过分析数据中真实信息（abstract 字段）的高频词汇，构建了包含根据、显示、证实等词语的词表。

（2）风格特征：选取了文本长度、标点符号使用频率（如感叹号、问号）等特征，用以反映文本的书面化程度和情绪强烈程度。

2. 特征变量（12 个）

类别	特征名	含义	设计动机（谣言 vs 事实）
1	**length**	文本总字符数	控制变量，谣言可能追求简短有力，事实可能更详细
2	**exclamation_count**	感叹号数量	谣言更倾向使用感叹号煽动情绪、制造紧迫感
3	**question_count**	问号数量	谣言可能多用反问或疑问句吸引注意
4	**digit_density**	数字密度	事实文本常包含具体数字（确诊数、日期），密度应更高
5	**uncertainty_count**	不确定性词次数	谣言多用模糊、未经证实的表述
6	**extreme_count**	极端情绪词次数	谣言倾向制造恐慌或极端情绪
7	**fact_word_count**	客观事实词次数	事实文本倾向于引用权威、数据、官方来源
8	**first_person_count**	第一人称代词次数	谣言可能用第一人称增加可信度（“我朋友说”）
9	**avg_sentence_length**	平均句子长度（字符）	事实文本句子可能更复杂、更长
10	**sentiment**	情感得分 (0~1)	谣言通常更负面（得分低），也可能有虚假乐观
11	**capital_ratio**	英文字母比例	事实中可能出现英文术语或引用，比例略高；或谣言用英文伪装专业
12	**ellipsis_count**	省略号数量	谣言可能用省略号制造悬念、未完待续感



3. 实验设置

- 数据划分：80%训练，20%测试，采用分层抽样保持类别比例。
- 标准化：对特征矩阵进行 Z-score 标准化。
- 模型：逻辑回归（LR）和随机森林（RF），均设置 class_weight='balanced'以处理不平衡。
- 评估指标：准确率（Accuracy）、AUC、精确率（Precision）、召回率（Recall）、F1 值。

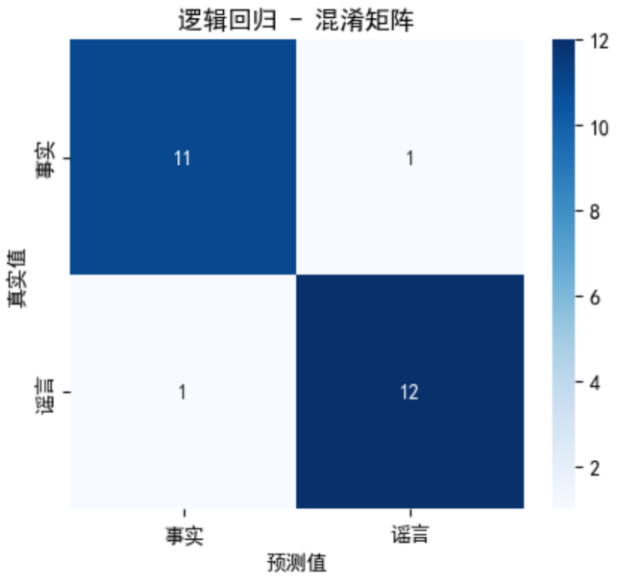
4. 平衡数据集结果

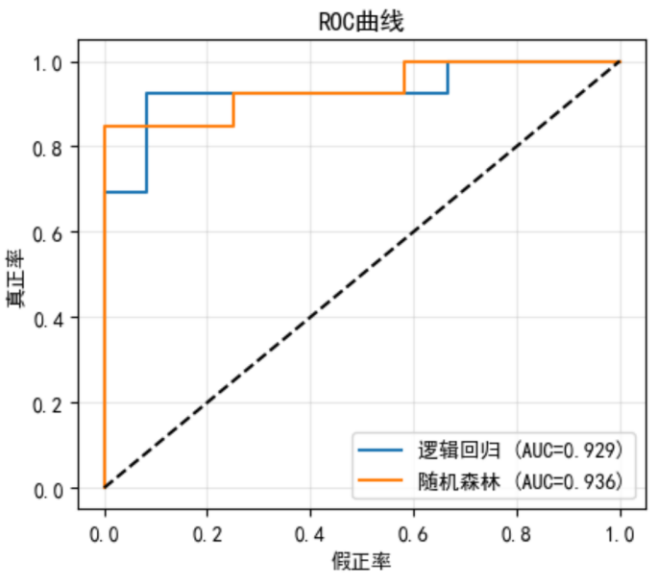
特征模型性能对比（平衡数据集，测试集 25 条）

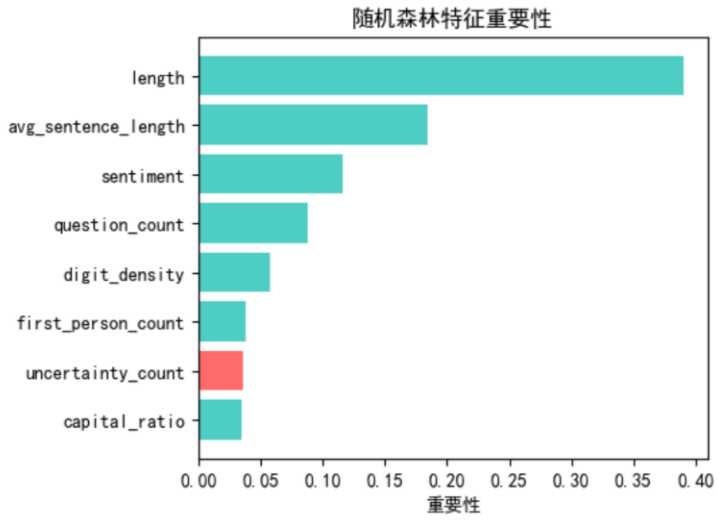
模型	类别	精确率	召回率	F1-score	支持数
逻辑回归	事实	0.92	0.92	0.92	12
	谣言	0.92	0.92	0.92	13
	准确率	**0.92**			25
随机森林	事实	0.85	0.92	0.88	12
	谣言	0.92	0.85	0.88	13
	准确率	**0.88**			25

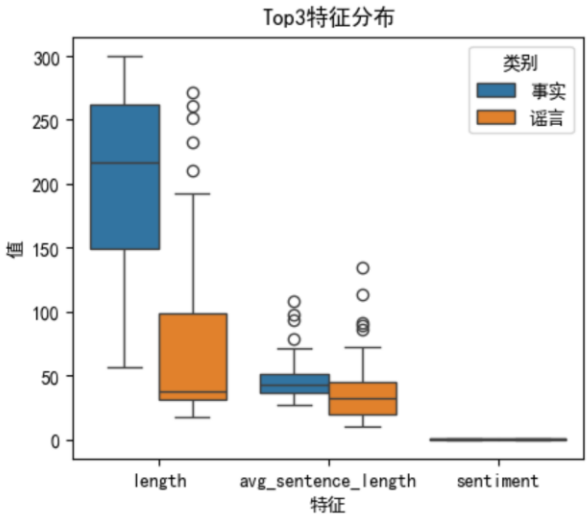
逻辑回归在准确率、精确率、召回率和 F1-score 上均达到 0.92，显著优于随机森林的 0.88。

这表明对于本文设计的 12 个统计特征，线性分类器（逻辑回归）比非线性集成模型（随机森林）更有效，可能是因为特征之间近似线性可分，且逻辑回归对特征噪声更鲁棒。









随机森林的特征重要性排序显示，文本长度（length）、平均句子长度（avg_sentence_length）和情感得分（sentiment） 位列前三。可能原因：

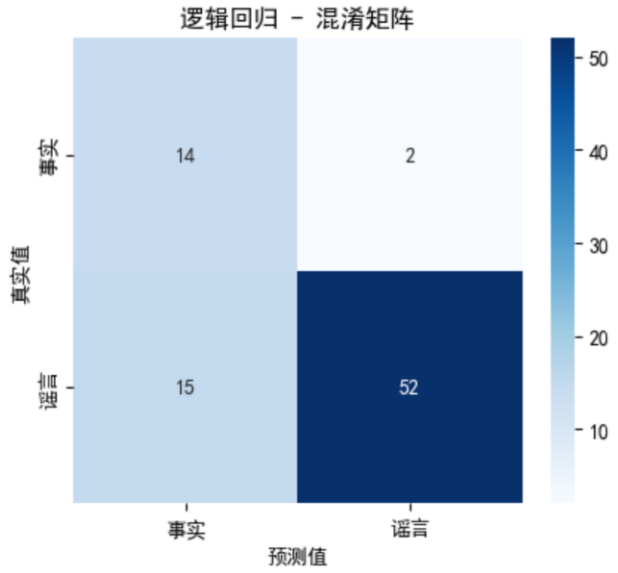
- 平衡数据集中谣言和事实在长度和句子复杂度上差异明显（谣言往往更短、句子结构更简单）。
- 情感得分（SnowNLP）有效捕捉了谣言更负面的倾向。
- 不确定性词和极端情绪词的重要性相对靠后，说明在纯净的谣言-事实对中，浅层结构特征比特定词汇更具区分度。

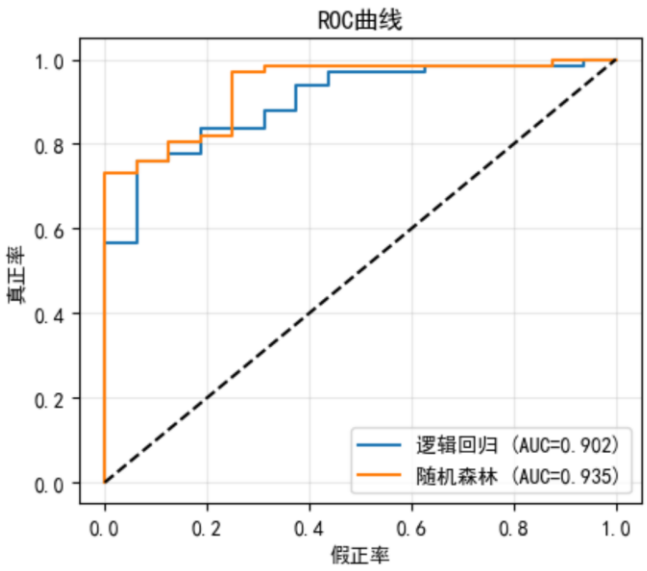
5．完整数据集结果

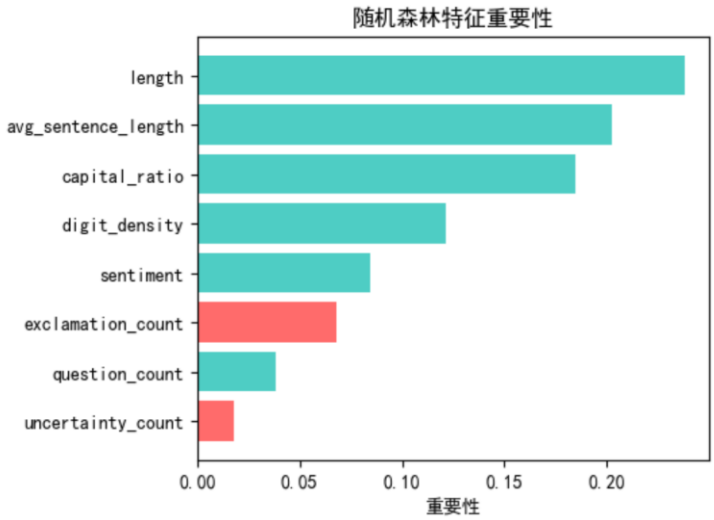
完整数据集特征模型性能对比（测试集 83 条）

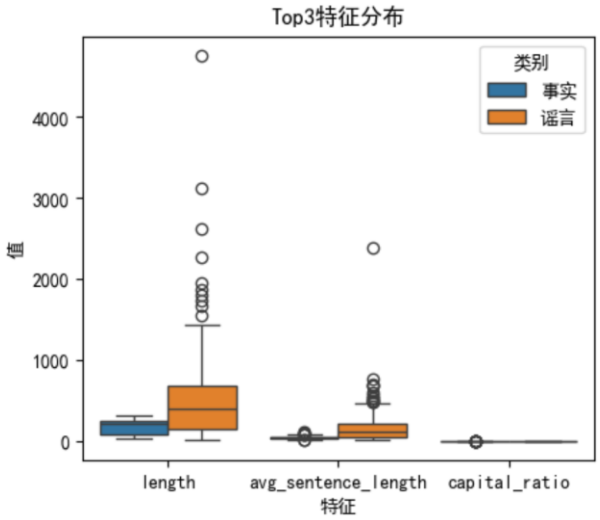
模型	类别	精确率	召回率	F1-score	支持数
逻辑回归	事实	0.48	0.88	0.62	16
	谣言	0.96	0.78	0.86	67
	准确率	**0.80**			83
随机森林	事实	0.86	0.75	0.80	16
	谣言	0.94	0.97	0.96	67
	准确率	**0.93**			83

相比平衡数据集（逻辑回归 92%），逻辑回归在完整数据集上大幅下降，而随机森林反而提升至 93%。这主要是因为数据严重不平衡（事实仅占 19%），逻辑回归作为线性模型更易受类别分布影响，倾向于牺牲少数类（事实）的精确率来换取召回率（事实召回率 0.88，但精确率仅 0.48）。相反，随机森林通过集成学习和类别权重平衡，能够更好地处理不平衡数据。









特征重要性排序变化：

- length 仍然最重要，但权重下降。平衡数据中长度贡献近 40%，完整数据中降至 23.8%，说明加入微博谣言后，其他特征（如英文比例、感叹号）的区分作用增强。

- capital_ratio（英文字母比例）跃升至第三。在完整数据中，微博谣言文本极少包含英文（如“COVID-19”、“FDA”等专业术语），而事实文本中常见英文缩写或拉丁文命名（如病毒名称），使得该特征成为重要信号。
- exclamation_count（感叹号）重要性大幅提升。从平衡数据的 1.74%（最末）升至 6.79%（第 6）。这符合直觉：微博谣言更爱用感叹号煽动情绪、制造紧迫感，而腾讯/丁香园数据中文本较规范，感叹号区分度低。
- sentiment（情感得分）重要性略降，从 11.62%降至 8.45%，但仍居前五。表明微博谣言虽然情绪化，但事实文本也可能因报道负面新闻而偏低，情感极性不再是唯一强特征。
- uncertainty_count 和 extreme_count 始终不重要。两者在两类数据集中均排名靠后，说明预定义的“可能、据说”等词以及“死亡、爆发”等极端词并非谣言的核心特征。这可能因为事实文本中也经常引用这些词（例如官方通报中的“死亡病例”）。

四、 BERT 方法

由于 BERT 模型需要较大的数据量以避免过拟合，且特征方法已在平衡数据集上验证了基本区分能力，我将只在更贴近真实场景的完整数据集上对 BERT 进行微调。数据集划分与特征方法中的完整训练集一致。

```
train_texts, val_texts, train_labels, val_labels = train_test_split(
    df['text'].values,
    df['label'].values,
    test_size=0.2,
    random_state=42,
    stratify=df['label'].values
)
```

本次训练结果（学习率 2e-5，3 epoch）

Epoch	训练损失	验证准确率
1	0.3090	92.77%
2	0.1261	91.57%
3	0.0833	**95.18%**

由于数据量小，为避免过拟合之训练了 3 个 epoch 来确认通过 BERT 微调是否可以得到由于特征方法的结果。

- **收敛情况：训练损失从 0.309 持续下降至 0.083，说明模型在训练集上正常拟合。**
- **最佳性能：第 3 个 epoch 验证准确率达到最高 95.18%，且此时损失仍较低（未出现验证集准确率下降的同时损失骤降——之前过拟合的典型信号），表明模型具备较好的泛化能力。**
- 选择该 epoch 的模型：以此作为最终 BERT 模型，用于与特征方法对比。

与特征方法的最优结果（随机森林）进行比较：

模型	准确率	类别	精确率	召回率	F1-score
随机森林（特征）	92.8%	事实	0.86	0.75	0.80
		谣言	0.94	0.97	0.96
BERT	**95.2%**	事实	0.83	0.94	0.88
		谣言	0.98	0.96	0.97

- **整体准确率：BERT 较随机森林提升 2.4 个百分点（95.2% vs 92.8%），相对提升 2.6%。**
- **事实识别（少数类）：BERT 将事实的召回率从 0.75 大幅提升至 0.94，F1-score 从 0.80 提升至 0.88，显著减少了真实信息被误判为谣言的风险。**
- **谣言识别：BERT 的谣言精确率和 F1-score 均略高于随机森林，保持近乎完美的识别能力。**